# Chapitre 6 : Représentation des textes

## ISN

Année scolaire 2019/2020

**Introduction**

Le but de ce chapitre est de comprendre comment les textes sont représentés dans un ordinateur et d'apprendre à manipuler le type `str` de `Python` qui leur est dédié.

## 1 Chaînes de caractères en `Python`

### Méthode

☞ Une chaîne de caractères est une séquence éventuellement vide de caractères. Chaque caractère est une chaîne de longueur 1.

En `Python`, les chaînes de caractères définissent le type `str`. La longueur d'une chaîne de caractères s'obtient avec la fonction `len`.

```
In [6]: a = 1

In [7]: type(a)
Out[7]: int

In [8]: b = str(a)

In [9]: b, type(b)
Out[9]: ('1', str)

In [10]: len(b), len('un'), len('')
Out[10]: (1, 2, 0)
```

☞ Les chaînes de caractères partagent certaines propriétés avec les listes :

– Une chaîne de caractères `chaine` peut être vue comme un tableau de caractères indexés de 0 à `len(chaine) - 1` de gauche à droite et de `-1` à `-len(chaine)` de droite à gauche. L'opérateur crochet permet d'accéder au caractère d'index `i` avec la syntaxe `chaine[i]` ou à la tranche de caractères d'index appartenant à l'intervalle $[i;j[$ avec la syntaxe `chaine[i:j]` si $0 \leqslant i \leqslant j$ ou à l'intervalle $]j;i]$ avec la syntaxe `chaine[i:j:-1]` si $-1 \geqslant i \geqslant j$.

```
In [26]: chaine = 'XYT'
Out[26]: ('X', 'Y', 'T')
```

```
In [27]: chaine[0], chaine[1], chaine[len(chaine)-1]
Out[27]: ('X', 'Y', 'T')

In [28]: chaine[-1], chaine[-2], chaine[-len(chaine)]
Out[28]: ('T', 'Z', 'X')

In [29]: chaine[1:3], chaine[-1:-len(chaine):-1]
Out[29]: ('YZ', 'TZY')
```

- On peut itérer sur une chaîne de caractères avec une boucle `for`.

```
In [18]: for c in 'XY':
    ...:     print(c)
    ...:
X
Y
```

- On peut concaténer deux chaînes pour créer une nouvelle chaîne avec l'opérateur +.

```
In [19]: a, b, c = 'belle','-','ile'

In [20]: a + b + c
Out[20]: 'belle-ile'
```

☞ Une chaîne de caractères d'identifiant `chaine` est un objet `Python` qui intègre de nombreuses méthodes accessibles avec la notation pointée `chaine.methode()`. On peut les découvrir en saisissant `dir(chaine)` ou dans la documentation en ligne :

https://docs.python.org/3/library/stdtypes.html#text-sequence-type-str

```
In [24]: a = 'un beau marin'

In [25]: a.find('beau')
Out[25]: 3

In [26]: a.replace('b','v')
Out[26]: 'un veau marin'

In [27]: a.upper()
Out[27]: 'UN BEAU MARIN'

In [28]: 'un beau marin'.replace(' ', '')
Out[28]: 'unbeaumarin'

In [29]: dir(a)
Out[29]: ['__add__',
 '__class__',
 '__contains__',
....
```

### Exercice 1

1. Compléter le code de la fonction `miroir` qui prend en paramètre une chaîne de caractères, pour qu'elle retourne la chaîne de caractères renversée :

```
def miroir(chaine):
    res = ''
    for c in chaine:
        ..............
        ..............
    return res
```

```
In [33]: miroir('Suis-je toujours la plus belle?')
Out[33]: '?elleb sulp al sruojuot ej-siuS'
```

2. Écrire une fonction `palindrome(chaine)` qui retourne un booléen indiquant si la chaîne de caractères est un palindrome. Cette fonction ne doit pas tenir compte des espaces.

```
In [38]: palindrome('caser vite ce palindrome ne mord ni lape cet
     ivre sac')
Out[38]: True
```

.....

.....

.....

.....

.....

.....

# 2 Du code ASCII à l'Unicode

## 2.1 Table de codage ASCII

Pour représenter de manière informatique un texte, il faut commencer par se donner une correspondance entre lettres et nombres. C'est ici qu'interviennent les tables de codages.

### Définition 1 *(Table de codage)*

**Une table de codage** ou **jeu de caractères** ou **charset** ou **code point** permet d'associer un caractère qu'on souhaite coder à un code unique.

Au début des années 1960, devant la multiplication des encodages de caractères et leurs incompatibilités mutuelles, l'ANSI (*American National Standards Institute*), définit une norme appelée **ASCII** (*American Standard Code for Information Interchange*).
Ce standard permet de coder 128 caractères sur 7 bits ($2^7 = 128$), le bit de poids fort étant réservé à des contrôles d'erreur : ce bit de parité est choisi pour que le nombre total de bits à 1 dans l'octet soit toujours pair.

La table de codage **ASCII** représentée ci-dessous contient :

- les lettres de l'alphabet latin en majuscule et minuscule et les chiffres de 0 à 9 ;
- des signes de ponctuation et des opérateurs arithmétiques ;
- des caractères spéciaux (tabulation, retour chariot, nouvelle ligne ...) et des caractères de contrôle non imprimables pour des protocole de communication et des contrôles de périphériques (Fin de transmission, EOT, demande de transmission ENQ ...).

**La table de codage ASCII :**

| Hex | Dec | Char | | Hex | Dec | Char | Hex | Dec | Char | Hex | Dec | Char |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| 0x00 | 0 | NULL | null | 0x20 | 32 | Space | 0x40 | 64 | @ | 0x60 | 96 | ` |
| 0x01 | 1 | SOH | Start of heading | 0x21 | 33 | ! | 0x41 | 65 | A | 0x61 | 97 | a |
| 0x02 | 2 | STX | Start of text | 0x22 | 34 | " | 0x42 | 66 | B | 0x62 | 98 | b |
| 0x03 | 3 | ETX | End of text | 0x23 | 35 | # | 0x43 | 67 | C | 0x63 | 99 | c |
| 0x04 | 4 | EOT | End of transmission | 0x24 | 36 | $ | 0x44 | 68 | D | 0x64 | 100 | d |
| 0x05 | 5 | ENQ | Enquiry | 0x25 | 37 | % | 0x45 | 69 | E | 0x65 | 101 | e |
| 0x06 | 6 | ACK | Acknowledge | 0x26 | 38 | & | 0x46 | 70 | F | 0x66 | 102 | f |
| 0x07 | 7 | BELL | Bell | 0x27 | 39 | ' | 0x47 | 71 | G | 0x67 | 103 | g |
| 0x08 | 8 | BS | Backspace | 0x28 | 40 | ( | 0x48 | 72 | H | 0x68 | 104 | h |
| 0x09 | 9 | TAB | Horizontal tab | 0x29 | 41 | ) | 0x49 | 73 | I | 0x69 | 105 | i |
| 0x0A | 10 | LF | New line | 0x2A | 42 | * | 0x4A | 74 | J | 0x6A | 106 | j |
| 0x0B | 11 | VT | Vertical tab | 0x2B | 43 | + | 0x4B | 75 | K | 0x6B | 107 | k |
| 0x0C | 12 | FF | Form Feed | 0x2C | 44 | , | 0x4C | 76 | L | 0x6C | 108 | l |
| 0x0D | 13 | CR | Carriage return | 0x2D | 45 | - | 0x4D | 77 | M | 0x6D | 109 | m |
| 0x0E | 14 | SO | Shift out | 0x2E | 46 | . | 0x4E | 78 | N | 0x6E | 110 | n |
| 0x0F | 15 | SI | Shift in | 0x2F | 47 | / | 0x4F | 79 | O | 0x6F | 111 | o |
| 0x10 | 16 | DLE | Data link escape | 0x30 | 48 | 0 | 0x50 | 80 | P | 0x70 | 112 | p |
| 0x11 | 17 | DC1 | Device control 1 | 0x31 | 49 | 1 | 0x51 | 81 | Q | 0x71 | 113 | q |
| 0x12 | 18 | DC2 | Device control 2 | 0x32 | 50 | 2 | 0x52 | 82 | R | 0x72 | 114 | r |
| 0x13 | 19 | DC3 | Device control 3 | 0x33 | 51 | 3 | 0x53 | 83 | S | 0x73 | 115 | s |
| 0x14 | 20 | DC4 | Device control 4 | 0x34 | 52 | 4 | 0x54 | 84 | T | 0x74 | 116 | t |
| 0x15 | 21 | NAK | Negative ack | 0x35 | 53 | 5 | 0x55 | 85 | U | 0x75 | 117 | u |
| 0x16 | 22 | SYN | Synchronous idle | 0x36 | 54 | 6 | 0x56 | 86 | V | 0x76 | 118 | v |
| 0x17 | 23 | ETB | End transmission block | 0x37 | 55 | 7 | 0x57 | 87 | W | 0x77 | 119 | w |
| 0x18 | 24 | CAN | Cancel | 0x38 | 56 | 8 | 0x58 | 88 | X | 0x78 | 120 | x |
| 0x19 | 25 | EM | End of medium | 0x39 | 57 | 9 | 0x59 | 89 | Y | 0x79 | 121 | y |
| 0x1A | 26 | SUB | Substitute | 0x3A | 58 | : | 0x5A | 90 | Z | 0x7A | 122 | z |
| 0x1B | 27 | FSC | Escape | 0x3B | 59 | ; | 0x5B | 91 | [ | 0x7B | 123 | { |
| 0x1C | 28 | FS | File separator | 0x3C | 60 | < | 0x5C | 92 | \ | 0x7C | 124 | \| |
| 0x1D | 29 | GS | Group separator | 0x3D | 61 | = | 0x5D | 93 | ] | 0x7D | 125 | } |
| 0x1E | 30 | RS | Record separator | 0x3E | 62 | > | 0x5E | 94 | ^ | 0x7E | 126 | ~ |
| 0x1F | 31 | US | Unit separator | 0x3F | 63 | ? | 0x5F | 95 | _ | 0x7F | 127 | DEL |

## Exercice 2

En Python, la fonction ord associe à un caractère son code ASCII (en fait Unicode) et la fonction chr est sa réciproque :

```
In [39]: ord('a'), ord('z'), ord('A'), ord('Z')
Out[39]: (97, 122, 65, 90)

In [40]: chr(65), chr(90)
Out[40]: ('A', 'Z')

In [41]: [chr(ord('a') + k) for k in range(26)]
Out[41]: ['a', 'b', 'c', ..... ,'y', 'z']

In [42]: ''.join([chr(ord('a') + k) for k in range(26)])
Out[42]: 'abcdefghijklmnopqrstuvwxyz'
```

1. Définir le chiffrement d'une chaîne de caractères par l'algorithme rot13.

   Ressources : https://fr.wikipedia.org/wiki/ROT13

   .....

   .....

2. L'image par rot13 du caractère 'H' est 'E'.

   - on calcule d'abord le rang alphabétique d'un caractère :

     ```
     In [56]: ord('R') - ord('A')
     Out[56]: 17
     ```

   - puis on ajoute 13 à ce rang et on prend le reste dans la division euclidienne par 26

     ```
     In [59]: (ord('R') - ord('A') + 13) % 26
     Out[59]: 4
     ```

   - enfin on retrouve le rang du caractère associé au rang alphabétique calculé :

     ```
     In [60]: chr(ord('A') + 4)
     Out[60]: 'E'
     ```

   Écrire une fonction rot13(chaine) qui chiffre ou déchiffre la chaîne (en majuscules ou convertie en majuscules avec chaine.upper()) passée en paramètre, avec l'algorithme rot13.

   .....

   .....

   .....

   .....

   .....

### Exercice 3 *Défi Turing problème 165*

Le fichier `dico.txt` contient 323 471 mots français non accentués. En associant à chaque lettre son rang dans l'alphabet (a=1, b=2, c=3, ..., z=26), puis en multipliant entre elles toutes les lettres d'un mot, on obtient un nombre.
Par exemple, "chaud" = $3 \times 8 \times 1 \times 21 \times 4 = 2016$.
Si l'on applique ce procédé à tous les mots du fichier `dico.txt`, quelle est l'année du troisième millénaire qui sera atteinte le plus souvent?

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

*Plus de défis sur* http://apprendre-en-ligne.net/turing/enonces.php.

## 2.2 Tables de codages ISO-8859

Les caractères de la table **ASCII** se sont vite avérés insuffisants pour l'encodage de textes dans d'autres langues que l'Anglais qui ne comprend pas de caractères accentués par exemple. Pour y remédier, l'**ISO** (*Organisation internationale de normalisation*) a proposé la norme **ISO-8859** qui étend la table **ASCII** en utilisant le huitième bit. Sur un octet, on peut ainsi représenter deux fois plus de caractères, soit $2^8 = 256$.
La norme **ISO 8859** comprend seize tables de codages, certes compatibles entre elles et avec ASCII sur les 128 premiers caractères, mais avec 256 caractères il n'est pas possible d'écrire un texte avec un mélange de caractères arabes et russes.
De plus, avec la mondialisation des échanges numériques et la multiplication des encodages, les problèmes d'incompatibilité d'encodages se sont multipliés. Qui n'a jamais reçu de courriel avec d'étranges caractères comme ci-dessous?

```
Je transf??re le message ?? Valentin
```

L'encodage du message n'étant pas reconnu par le client de messagerie, les caractères accentués `è` et `à` ont été remplacés par des signes `?`.

## 2.3 Table de codage universelle et encodages Unicode

Pour assurer l'universalité de la représentation des caractères, l'**ISO** a défini une table de codage universelle, l'*Universal Character Set* sous la norme **ISO-10646**. Cette norme associe à chaque caractère un unique

nombre appelé **point de code** et permet de représenter $2^{32}$ = 4 294 967 296 caractères. Actuellement, 110 000 caractères sont recensés.
Chaque point de code est de la forme `U+xxxx` où chaque chiffre `x` est un caractère hexadécimal (base 16) avec au moins quatre chiffres.
Il est possible d'encoder chaque point de code sur 4 octets mais des encodages plus compacts ont été imaginés dans la norme **Unicode**. En effet, il suffit d'un octet pour stocker les caractères **ASCII** et de deux octets pour les plus courants dont le point de code est compris entre 0 et $2^{16} - 1 = 65\,535$.
Les encodages **Unicode** sont notés **UTF-***n* où $n$ est le nombre minimal de bits pour représenter un point de code.
L'encodage **Unicode** le plus courant est **UTF-8**.

## Exercice 4

Sur la page `https://unicode-table.com/fr/` se trouve un moteur de recherche de caractère par **point de code**.

1. Déterminer la valeur en décimal (base 10) du point de code `U+ABCD`.

   .....

2. Rechercher le caractère dont le point de code est `U+263A`.

   .....

3. Tester puis expliquer le code ci-dessous :

```
pointcode = 0x263A
print(pointcode)
for k in range(10):
    print(chr(pointcode))
    pointcode = pointcode + 1
```

   .....

   .....

4. En `Python`, pour saisir directement un caractère à partir de son point de code, on peut utiliser des séquences d'échappement spéciales : `'\uxxxx'` si le point de code peut s'écrire avec 4 chiffres hexadécimaux, ou `'\Uxxxxxxxx'` s'il faut plus de quatre chiffres, en remplissant par des 0 à gauche les positions vides sur les huit possibles. Néanmoins il est plus pratique d'utiliser `chr` avec comme argument le point de code en décimal ou en hexadécimal.

   a. Tester l'instruction ci-dessous dans une console `Python`

```
In [11]: print("\U0001f600")

OU [11] : ...................
```

**b.** Écrire un code `Python` qui affiche tous les caractères dont le point de code est compris entre `U+1F600` et `U+Ff64F`.

.....

.....

.....

.....

## Méthode

Les méthodes `encode` et `decode` permettent de transformer une chaîne de caractères de type `'str'` en séquence d'octets de type `'bytes'` et réciproquement. Il faut préciser l'encodage.

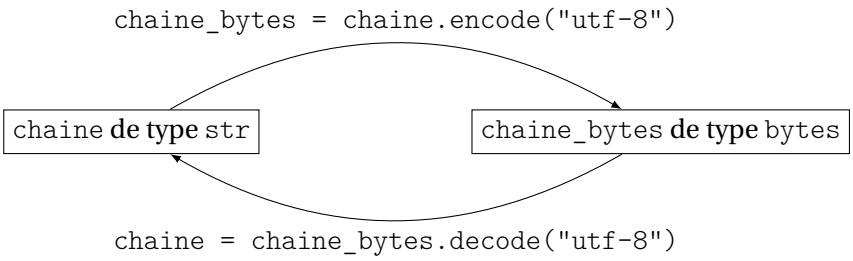


Les octets d'une séquence d'octets de type `bytes` sont représentés par le caractère ASCII correspondant s'ils ont une valeur inférieure ou égale à 127 (`7F` en hexadécimal) ou par leur valeur hexadécimale préfixée de la séquence `\x`. Par exemple le caractère `'é'` est codé en **UTF-8** sur deux octets de valeurs hexadécimales `C3` et `A9`. En **ISO-8859-1** ou **Latin1**, le caractère `'é'` est codé sur un seul octet. On peut mettre en évidence les incompatibilités de ces deux encodages pour les caractères non ASCII.

```
In [35]: "lycée".encode("utf-8")
Out[35]: b'lyc\xc3\xa9e'

In [36]: b'lyc\xc3\xa9e'.decode("utf-8")
Out[36]: 'lycée'

In [37]: "lycée".encode("latin1")
Out[37]: b'lyc\xe9e'

In [38]: b'lyc\xe9e'.decode("utf-8")
---------------------------------------------------------------------------

UnicodeDecodeError: 'utf-8' codec can't decode byte 0xe9 in position 3:
    invalid continuation byte
```

## Exercice 5

Le principe de l'encodage **UTF-8** est le suivant :

- Si le bit de poids fort du premier octet lu est 0 alors il s'agit d'un caractère ASCII codé sur les 7 bits restants.
- Sinon, le nombre de bits de poids forts successifs du premier octet qui sont à 1 donne le nombre d'octets sur lequel le caractère est encodé. Chaque octet suivant commence par la séquence de deux bits 10 et le point de code en binaire est encodé sur les bits qui ne sont pas utilisés pour le formatage.

  Par exemple le caractère de point de code `U+263A` soit 9786 en décimal et $\overbrace{10}^{\text{octet 1}}\,\overbrace{011000}^{\text{octet 2}}\overbrace{111010}^{\text{octet 3}}{}^{2}$ en binaire est encodé sur trois octets par :

$$\overbrace{\underbrace{111}_{\text{format}}\,\underbrace{00010}_{\text{codage}}}^{\text{octet 1}}\quad\overbrace{\underbrace{10}_{\text{format}}\,\underbrace{011000}_{\text{codage}}}^{\text{octet 2}}\quad\overbrace{\underbrace{10}_{\text{format}}\,\underbrace{111010}_{\text{codage}}}^{\text{octet 3}}$$

| Plage de points de code | Séquence d'octets (en binaire) | bits codants |
|---|---|---|
| `U+0000` (0) à `U+007F` (127) (ASCII) | `0xxxxxxx` | 7 bits |
| `U+008F` (128) à `U+07FF` (2047) | `110xxxxx 10xxxxxx` | 11 bits |
| `U+0800` (2048) à `U+FFFF` (65535) | `1110xxxx 10xxxxxx 10xxxxxx` | 16 bits |
| `U+10000` (65536) à `U+10FFF` (1114111) | `110xxxxx 10xxxxxx 10xxxxxx 10xxxxxx` | 21 bits |

**1.** Combien de caractères peut-on encoder en **UTF-8** ?

.....

**2.** Sur combien de caractères sont encodés les caractères accentués en **UTF-8** ?

.....

**3.** Écrire une fonction `unicode(s)` qui affiche pour chaque caractère de la chaîne `s`, le caractère `s`, son point de code et son encodage `UTF-8` sous forme d'octets en hexadécimal puis en binaire.

.....

.....

.....

.....

.....

**4.** Déterminer l'encodage `UTF-8` en donnant les octets en décimal, en binaire et en hexadécimal des caractères suivants :

**a.** le caractère @ de point de code `U+0040`

.....

**b.** le caractère æ de point de code `U+00E6`

.....

**c.** le caractère ℚ de point de code `U+211A`

.....

**5.** Écrire en `Python` une fonction `longueur(b)` qui parcours une chaîne d'octets de type `bytes` encodée en **UTF-8** et qui retourne le nombre de caractères représentés.

 Il est interdit de convertir la séquence d'octets en chaîne de caractères avec la méthode `decode`.

.....

.....

.....

.....

.....

.....

.....

.....

**Sources :**

*Le contenu de ce cours et certains exercices sont directement inspirés du chapitre 21 du* Manuel de première NSI *chez Ellipses.*